

# Chap.4 인공 신경망 (Artificial Neural Network)

---

방 수 식 교수  
(bang@tukorea.ac.kr)


한국공학대학교 전자공학부

2024년도 1학기  
머신러닝실습 & 인공지능설계실습1


# 신경망 (Neural Network)



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.



Neuron



Neural Network in Brain

- 축색종단에서의 도파민(신경전달물질) 분비 여부
  - 전달된 신호의 강도에 따라 결정됨
  - 즉, 신호의 강도가 임계값을 넘으면 도파민 분비 → **활성화**
  - 신호의 강도가 임계값을 넘지 않으면 도파민 분비되지 않음 → **비활성화**


## ■ Neuron의 핵심 기능

### ○ 전파(Propagation) 기능

- 신호(도파민)를 받아 전달


### ○ 활성화(Activation) 기능

- 신호의 강도에 따라 신호 활성화 유무를 결정



## ■ Artificial Neuron(인공 뉴런)

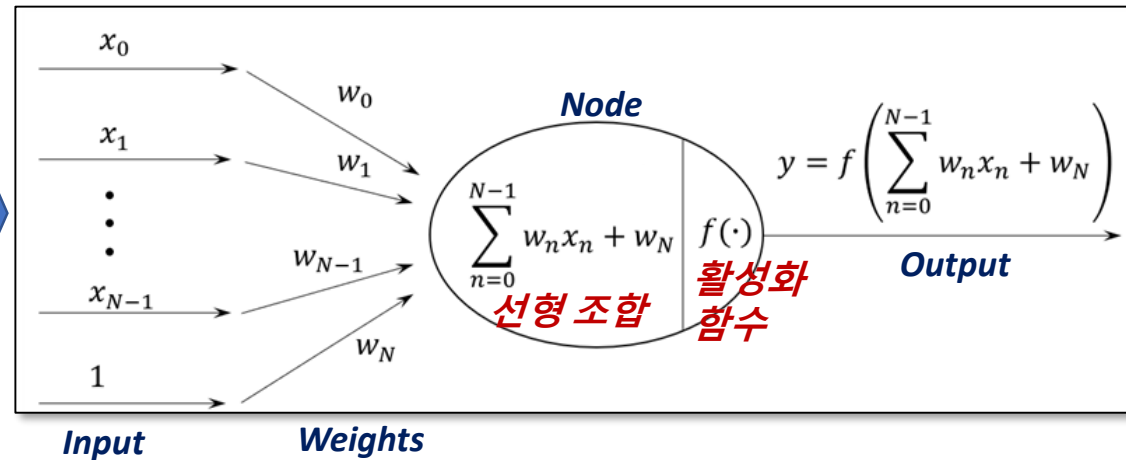

- Neuron 세포를 모방하여 설계



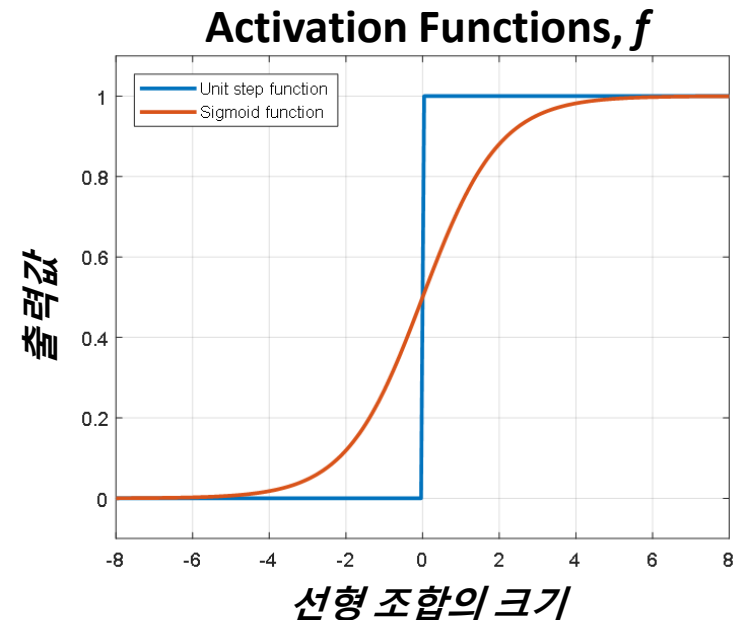
# Artificial Neuron



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.



- 전파(Propagation) 기능
  - 입력과 Weights 들의 선형 조합을 전파
- 활성화(Activation) 기능
  - 선형 조합의 크기에 따라 다음 뉴런에 전달할지 여부를 결정

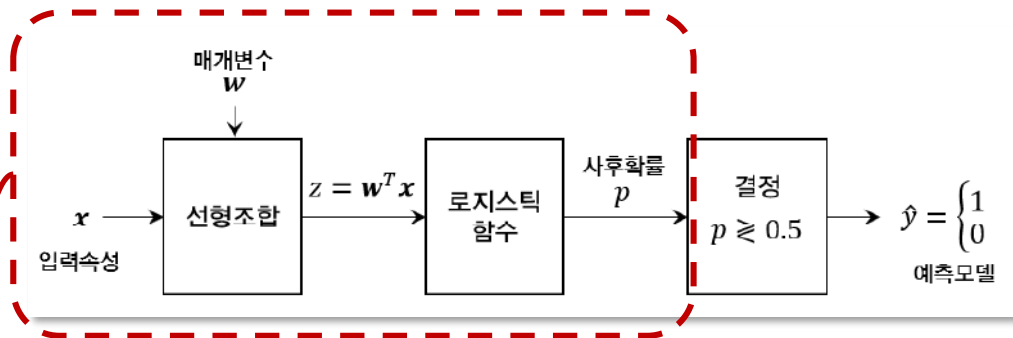


# Logistic Regression과의 비교




## Artificial Neuron의 관점에서의 Logistic Regression

- 일반적인 Logistic Regression 모델




- Sigmoid 함수를 Activation Function으로 사용하는 Artificial Neuron과 동일한 구조



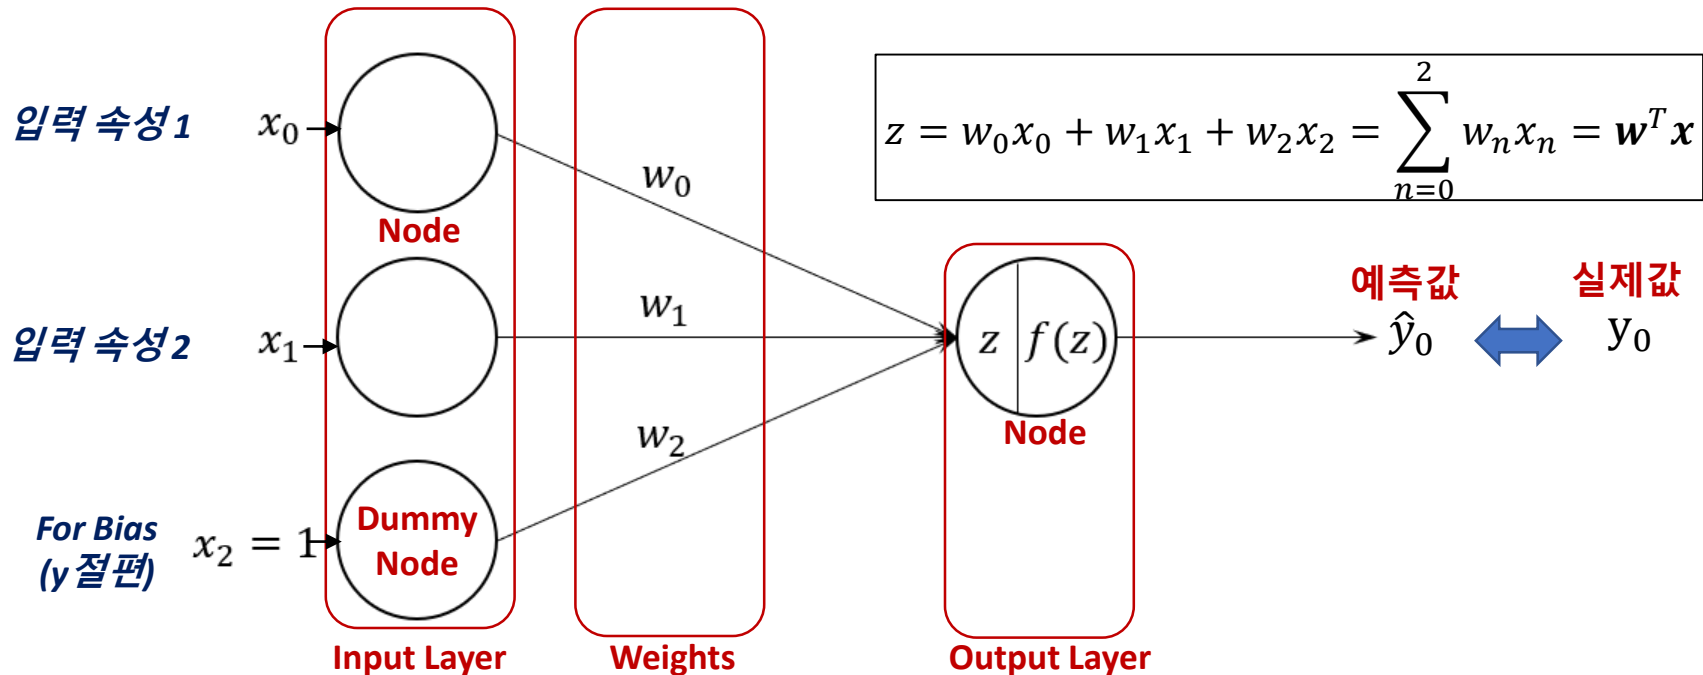
## ■ 퍼셉트론 (Perceptron)

- 입력층과 출력층 만으로 구성된 Single-Layer Neural Network
  - Neural Network의 기본 구성 단위
  - Binary Classification 시스템 (출력이 0 or 1)
  - (예) 입력 속성이 2개인 Perceptron



## ■ 퍼셉트론 (Perceptron)

- Node: 해당 Node로 들어온 모든 값을 더한 다음 **Activation Function**을 통과시킨 값을 출력
  - Input node의 Activation Function:  $f(x)=x$  (별도표기하지 않음)
- 화살표: 화살표 위에 적힌 weight만큼 곱 연산을 수행
  - 별도 표기가 없는 화살표의 weight는 1




분류해야하는 Class가 3개 이상이라면?

# Multi-Class Classification in Single Layer



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.



## ■ One-Hot Encoding (범주형 Class의 이진화)


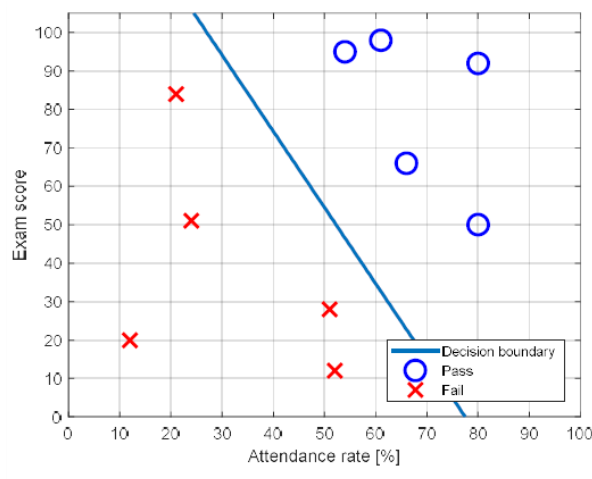

- 확률론적 접근 + 기계가 인식 가능한 숫자
  - ✓ Binary Class: 음성 or 양성 => 0 or 1
  - ✓ Multi-Class: 개 or 고양이 or 말 => 100 or 010 or 001  
( $y_0, y_1, y_2$ )



# Single Layer Neural Network의 한계




- Single Layer Neural Network의 한계
  - 단층 신경망은 로지스틱 회귀의 성능과 동일
  - 속성 공간의 “선형 분할”만 가능
    - Decision Boundary가 선형적



# Multi-Layer Neural Network



## • Two-Layer Neural Network



### • Input layer (입력층)

- 2 Input: 일반노드 2개 + 더미노드 1개 <= 데이터의 Input 속성 수에 의해 결정

### • Hidden Layer (은닉층)

- 일반노드 2개 + 더미노드 1개 <= 모델 설계자가 결정 (Hyper-parameter)

### • Output Layer (출력층)


- 3-Class: 일반노드 3개 <= 데이터의 Output class 수에 의해 결정

# Multi-Layer Neural Network



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.

## Node 별 입출력 계산



### Hidden Layer 입출력 관계

$$\alpha_0 = v_{00}x_0 + v_{10}x_1 + v_{20}x_2$$

$$\alpha_1 = v_{01}x_0 + v_{11}x_1 + v_{21}x_2$$

$$b_0 = f_1(\alpha_0)$$

$$b_1 = f_1(\alpha_1) \quad b_2 = 1$$

$x_2 = 1$

### Output Layer 입출력

$$\beta_0 = w_{00}b_0 + w_{10}b_1 + w_{20}b_2$$

$$\hat{y}_0 = f_2(\beta_0)$$

$$\beta_1 = w_{01}b_0 + w_{11}b_1 + w_{21}b_2$$

$$\hat{y}_1 = f_2(\beta_1)$$

$$\beta_2 = w_{02}b_0 + w_{12}b_1 + w_{22}b_2$$

$$\hat{y}_2 = f_2(\beta_2)$$

## Artificial Neural Network(ANN) 모델의 학습 목표

$\hat{y}_0 \approx y_0, \hat{y}_1 \approx y_1, \hat{y}_2 \approx y_2$ 를 만족하는 최적 매개변수를 찾는다.

# Two-Layer Neural Network의 일반화



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.

## 2-Input, 3-Class with 2-Hidden node

*Dummy node는 일반적으로 카운팅하지 않음.*

### Hidden Layer 입출력 $x_2 = 1$

$$\alpha_0 = v_{00}x_0 + v_{10}x_1 + v_{20}x_2$$

$$\alpha_1 = v_{01}x_0 + v_{11}x_1 + v_{21}x_2$$

$$b_0 = f_1(\alpha_0)$$

$$b_1 = f_1(\alpha_1)$$

$$b_2 = 1$$

### Output Layer 입출력

$$\beta_0 = w_{00}b_0 + w_{10}b_1 + w_{20}b_2$$

$$\beta_1 = w_{01}b_0 + w_{11}b_1 + w_{21}b_2$$


$$\beta_2 = w_{02}b_0 + w_{12}b_1 + w_{22}b_2$$

$$\hat{y}_0 = f_2(\beta_0)$$

$$\hat{y}_1 = f_2(\beta_1)$$

$$\hat{y}_2 = f_2(\beta_2)$$

## M-Input, Q-Class with L-Hidden node



# Two-Layer Neural Network의 일반화



## 2-Input, 3-Class with 2-Hidden node

*Dummy node는 일반적으로 카운팅하지 않음.*

### Hidden Layer 입출력 $x_2 = 1$

$$\alpha_0 = v_{00}x_0 + v_{10}x_1 + v_{20}x_2$$

$$\alpha_1 = v_{01}x_0 + v_{11}x_1 + v_{21}x_2$$

$$b_0 = f_1(\alpha_0)$$

$$b_1 = f_1(\alpha_1)$$

$$b_2 = 1$$



### Output Layer 입출력

$$\beta_0 = w_{00}b_0 + w_{10}b_1 + w_{20}b_2$$

$$\beta_1 = w_{01}b_0 + w_{11}b_1 + w_{21}b_2$$

$$\beta_2 = w_{02}b_0 + w_{12}b_1 + w_{22}b_2$$

$$\hat{y}_0 = f_2(\beta_0)$$

$$\hat{y}_1 = f_2(\beta_1)$$

$$\hat{y}_2 = f_2(\beta_2)$$



## M-Input, Q-Class with L-Hidden node

### Hidden Layer 입출력 $x_M = 1$

$$\alpha_l = v_{0l}x_0 + v_{1l}x_1 + \cdots + v_{Ml}x_M = \sum_{m=0}^M v_{ml}x_m$$

$$l = 0, 1, \dots, L-1$$

$$b_l = f_1(\alpha_l) = f_1\left(\sum_{m=0}^M v_{ml}x_m\right) \quad b_L = 1$$

### Output Layer 입출력

$$\beta_q = w_{0q}b_0 + w_{1q}b_1 + \cdots + w_{Lq}b_L$$

$$= \sum_{l=0}^L w_{lq}b_l, \quad q = 0, 1, \dots, Q-1$$

$$\hat{y}_q = f_2(\beta_q) = f_2\left(\sum_{l=0}^L w_{lq}b_l\right)$$

# Two-Layer Neural Network의 일반화



- 1개의 데이터에 대해:  $M$ -Input,  $Q$ -Class with  $L$ -Hidden node 연산의 행렬화

## Hidden Layer 입력

$$\alpha_l = v_{0l}x_0 + v_{1l}x_1 + \cdots + v_{Ml}x_M = \sum_{m=0}^M v_{ml}x_m \quad x_M = 1$$

$$l = 0, 1, \dots, L-1$$

## Hidden Layer 출력

$$b_l = f_1(\alpha_l) = f_1\left(\sum_{m=0}^M v_{ml}x_m\right) \quad b_L = 1$$

$$\begin{aligned} b_0 &= f_1(\alpha_0) \\ b_1 &= f_1(\alpha_1) \\ &\vdots \\ b_l &= f_1(\alpha_l) \\ &\vdots \\ b_{L'} &= f_1(\alpha_{L'}) \\ b_L &= 1 \end{aligned} \quad \Rightarrow \quad \mathbf{b} = \begin{bmatrix} f_1(\alpha_0) \\ f_1(\alpha_1) \\ \vdots \\ f_1(\alpha_l) \\ \vdots \\ f_1(\alpha_{L'}) \\ 1 \end{bmatrix}$$

(L+1 by 1)

$L' = L - 1$  일 때,

$$\alpha_0 = v_{00}x_0 + v_{10}x_1 + \cdots + v_{M0}x_M$$

$$\alpha_1 = v_{01}x_0 + v_{11}x_1 + \cdots + v_{M1}x_M$$

$\vdots$

$$\alpha_l = v_{0l}x_0 + v_{1l}x_1 + \cdots + v_{Ml}x_M$$

$\vdots$

$$\alpha_{L'} = v_{0L'}x_0 + v_{1L'}x_1 + \cdots + v_{ML'}x_M$$

L개



$\alpha$  (L by 1)

$v$  (L by M+1)

$$\begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_l \\ \vdots \\ \alpha_{L'} \end{bmatrix} = \begin{bmatrix} v_{00} & v_{10} & \cdots & v_{M0} \\ v_{01} & v_{11} & \cdots & v_{M1} \\ \vdots & \vdots & \ddots & \vdots \\ v_{0l} & v_{1l} & \ddots & v_{Ml} \\ \vdots & \vdots & \ddots & \vdots \\ v_{0L'} & v_{1L'} & \cdots & v_{ML'} \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_M \end{bmatrix} \quad \mathbf{x} \text{ (M+1 by 1)}$$



$$\alpha = vx$$

# Two-Layer Neural Network의 일반화



- 1개의 데이터에 대해:  $M$ -Input,  $Q$ -Class with  $L$ -Hidden node 연산의 행렬화

Output Layer 입출력

$$\begin{aligned}\beta_q &= w_{0q}b_0 + w_{1q}b_1 + \cdots + w_{Lq}b_L + w_{Lq}b_L \\ &= \sum_{l=0}^L w_{lq}b_l, \quad q = 0, 1, \dots, Q-1 \\ \hat{y}_q &= f_2(\beta_q) = f_2\left(\sum_{l=0}^L w_{lq}b_l\right)\end{aligned}$$

$Q' = Q - 1$  일 때,

$\beta$  ( $Q$  by 1)

$w$  ( $Q$  by  $L+1$ )

$b$  ( $L+1$  by 1)

$$\begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_q \\ \vdots \\ \beta_{Q'} \end{bmatrix} = \begin{bmatrix} w_{00} & w_{10} & \cdots & w_{L0} \\ w_{01} & w_{11} & \cdots & w_{L1} \\ \vdots & \vdots & \ddots & \vdots \\ w_{0q} & w_{1q} & \ddots & w_{Lq} \\ \vdots & \vdots & \ddots & \vdots \\ w_{0Q'} & w_{1Q'} & \cdots & w_{LQ'} \end{bmatrix} \begin{bmatrix} f_1(\alpha_0) \\ f_1(\alpha_1) \\ \vdots \\ f_1(\alpha_l) \\ \vdots \\ f_1(\alpha_{L'}) \\ 1 \end{bmatrix}$$

↓  
 $\beta = wb$

$$\begin{matrix} (Q \text{ by } 1) \\ \hat{\mathbf{y}} = \end{matrix} \begin{bmatrix} \hat{y}_0 \\ \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_q \\ \vdots \\ \hat{y}_{Q-1} \end{bmatrix} = \begin{bmatrix} f_2(\beta_0) \\ f_2(\beta_1) \\ f_2(\beta_2) \\ \vdots \\ f_2(\beta_l) \\ \vdots \\ f_2(\beta_{Q-1}) \end{bmatrix}$$

# Two-Layer Neural Network의 일반화



## ■ N개의 데이터

데이터 번호	입력	출력
	$x_0, \dots, x_m, \dots, x_{M-1}$	$y_0, \dots, y_q, \dots, y_{Q-1}$
0	$x_{00}, \dots, x_{m0}, \dots, x_{(M-1)0}$	$y_{00}, \dots, y_{q0}, \dots, y_{(Q-1)0}$
$\vdots$	$\vdots$	$\vdots$
$n$	$x_{0n}, \dots, x_{mn}, \dots, x_{(M-1)n}$	$y_{0n}, \dots, y_{qn}, \dots, y_{(Q-1)n}$
$\vdots$	$\vdots$	$\vdots$
$N-1$	$x_{0(N-1)}, \dots, x_{m(N-1)}, \dots, x_{(M-1)(N-1)}$	$y_{0(N-1)}, \dots, y_{q(N-1)}, \dots, y_{(Q-1)(N-1)}$

❖ n번째 데이터에 대해서 (n은 0부터 N-1까지의 정수)

$$\begin{array}{c} \alpha \text{ (L by 1)} \\ \begin{bmatrix} \alpha_{0n} \\ \alpha_{1n} \\ \vdots \\ \alpha_{ln} \\ \vdots \\ \alpha_{L'n} \end{bmatrix} \end{array} = \begin{array}{c} v \text{ (L by M+1)} \\ \begin{bmatrix} v_{00} & v_{10} & \cdots & v_{M0} \\ v_{01} & v_{11} & \cdots & v_{M1} \\ & \vdots & \ddots & \vdots \\ v_{0l} & v_{1l} & \ddots & v_{Ml} \\ & \vdots & \ddots & \vdots \\ v_{0L'} & v_{1L'} & \cdots & v_{ML'} \end{bmatrix} \end{array} \begin{array}{c} x \text{ (M+1 by 1)} \\ \begin{bmatrix} x_{0n} \\ x_{1n} \\ \vdots \\ x_{Mn} \end{bmatrix} \end{array}$$

❖ Training 관점: n-1 번째 데이터로부터 업데이트 된 weights



# Chap.4 실습 - 1주차



*각 실습문제에 대해 code(+ 주석), 그래프, 분석 내용 등은 필수적으로 포함시킬 것*

## 1) One-Hot Encoding 구현

- 데이터에서의 y값(target) 으로부터 분류 할 Class가 몇 개인지 Check
- 각 Class에 대해 One-Hot 표현으로 변환
- “NN\_data.csv”에 적용

## 2) Two-Layer Neural Network 구현

- 데이터에서의 Input 속성 수 및 Output Class 수를 자동으로 Check하는 기능
- Hidden layer의 Node 수를 자유롭게 설정하는 기능
- Input 속성 수, Output Class 수, Hidden Node 수로부터 Weight Matrix 생성 및 초기화
- “NN\_data.csv”에 적용: 랜덤 초기화 된 Weight Matrix로부터  $\hat{y}$  값 도출


## 3) Accuracy 함수 구현

- $\hat{y}$  값에서 0.5를 기준으로 0 or 1로 변환
- 전체 Training set에 대해서  $\hat{y} = y$  인 데이터 개수 count => 정확도 계산

# Chap.4 실습 데이터



- 각 Class별 300개씩 총 1800개



- 1) Class1 :  $(x_0, x_1, x_2) = (1, 3, 5)$ 을 중심으로 노이즈가 추가된 데이터
- 2) Class2 :  $(x_0, x_1, x_2) = (3, 5, 7)$ 을 중심으로 노이즈가 추가된 데이터
- 3) Class3 :  $(x_0, x_1, x_2) = (5, 7, 9)$ 을 중심으로 노이즈가 추가된 데이터
- 4) Class4 :  $(x_0, x_1, x_2) = (7, 9, 5)$ 을 중심으로 노이즈가 추가된 데이터
- 5) Class5 :  $(x_0, x_1, x_2) = (9, 5, 3)$ 을 중심으로 노이즈가 추가된 데이터
- 6) Class6 :  $(x_0, x_1, x_2) = (5, 3, 1)$ 을 중심으로 노이즈가 추가된 데이터

## ■ Error Backpropagation (오차 역전파) 알고리즘

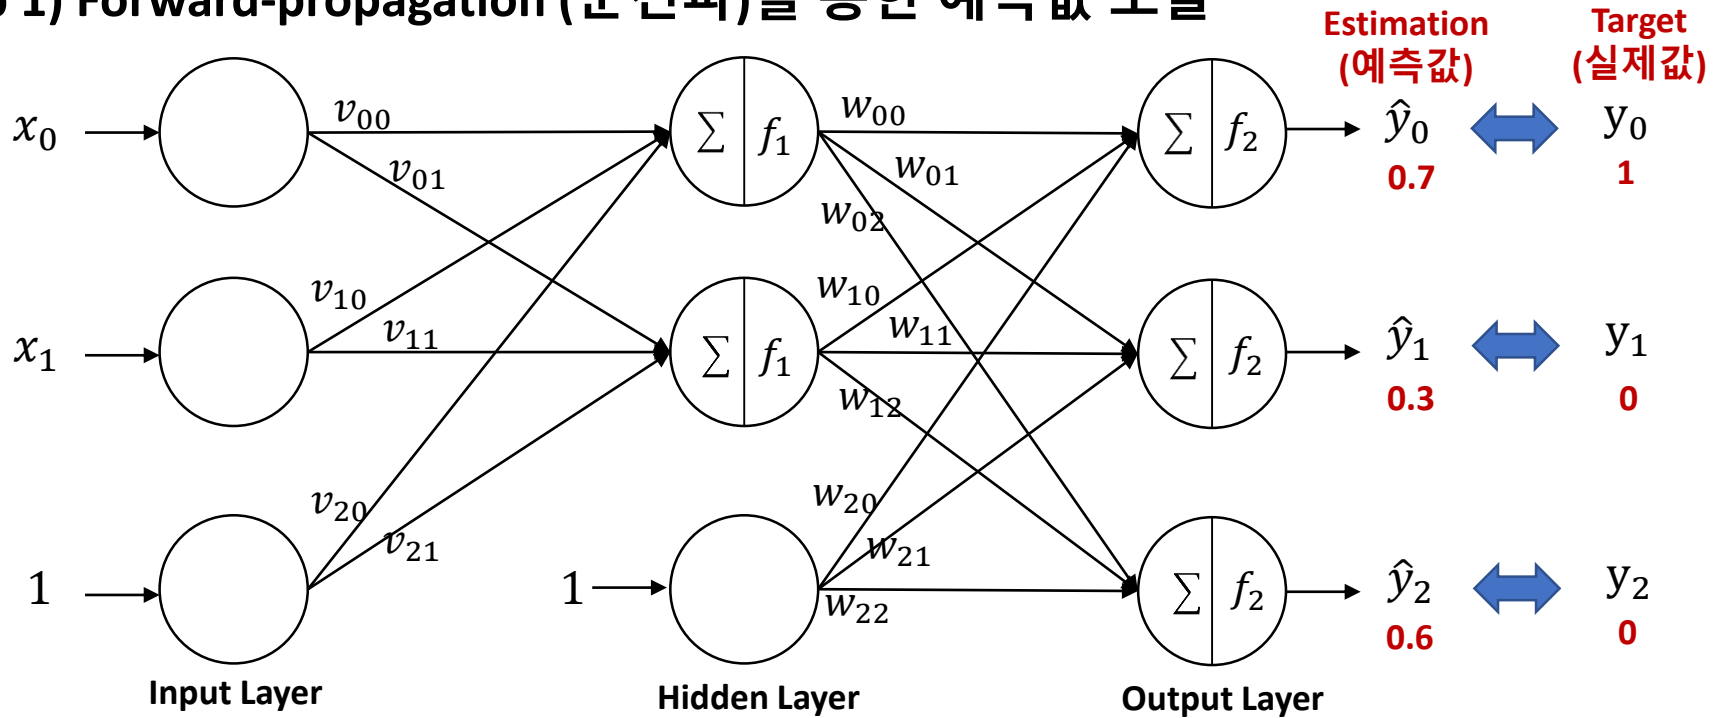
- 경사하강법 기반
- 개별 훈련 데이터에 대해서 알고리즘 적용
- 설정한 Cost Function로부터 모델의 예측값과 실측값 간의 Error 값으로부터 역으로 전파되면서 Weight를 업데이트함
  - ✓ 본 강의자료에서는 Activation Function은 Sigmoid, Cost Function은 MSE 기준으로 설명

# Error Back-Propagation 알고리즘




지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.

## Step 1) Forward-propagation (순전파)를 통한 예측값 도출



활성화함수  $f_1$ 과  $f_2$ 는 Sigmoid 함수로 선택하였다고 가정




- 예측값 계산 과정: Forward-propagation (순전파)
- Weight 업데이트 과정: Back-propagation(역전파)

# Error Back-Propagation 알고리즘



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.

## Step 2) 경사하강법을 통한 Weight 업데이트



❖ Cost Function을 MSE로 설정하였을 때, n번째 데이터에 대해서

$$v_{ml} \leftarrow v_{ml} - \eta \frac{\partial}{\partial v_{ml}} \epsilon_{MSE}(n)$$

$$w_{lq} \leftarrow w_{lq} - \eta \frac{\partial}{\partial w_{lq}} \epsilon_{MSE}(n)$$

$$\epsilon_{MSE}(n) = \sum_{q=0}^{Q-1} (\hat{y}_{qn} - y_{qn})^2$$


일단, 특정 weight에 대한 편미분 고려

# Error Back-Propagation 알고리즘



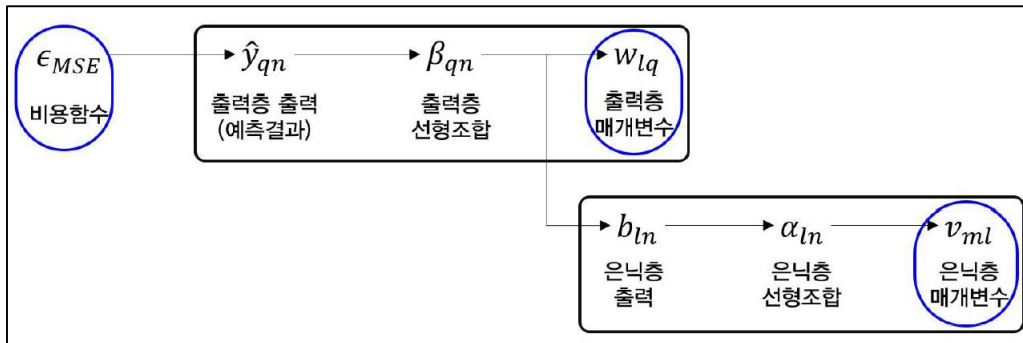
지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.

## Step 2-1) 경사하강법에서의 도함수 계산



Forward-propagation에  
사용한 weight (Old)

$$\begin{aligned} \text{New } v_{ml} &\leftarrow \text{Old } v_{ml} - \eta \frac{\partial}{\partial v_{ml}} \epsilon_{MSE}(n) \\ \text{New } w_{lq} &\leftarrow \text{Old } w_{lq} - \eta \frac{\partial}{\partial w_{lq}} \epsilon_{MSE}(n) \end{aligned}$$



$$\frac{\partial}{\partial w_{lq}} \epsilon_{MSE}(n) = \frac{\partial \epsilon_{MSE}(n)}{\partial \hat{y}_{qn}} \cdot \frac{\partial \hat{y}_{qn}}{\partial \beta_{qn}} \cdot \frac{\partial \beta_{qn}}{\partial w_{lq}}$$

$$\frac{\partial}{\partial v_{ml}} \epsilon_{MSE}(n) = \frac{\partial \epsilon_{MSE}(n)}{\partial b_{ln}} \cdot \frac{\partial b_{ln}}{\partial \alpha_{ln}} \cdot \frac{\partial \alpha_{ln}}{\partial v_{ml}}$$

# Error Back-Propagation 알고리즘



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.

- $\frac{\partial}{\partial w_{lq}} \epsilon_{MSE}(n)$  구하기

우변 1항

$$\frac{\partial}{\partial w_{lq}} \epsilon_{MSE}(n) = \underbrace{\frac{\partial \epsilon_{MSE}(n)}{\partial \hat{y}_{qn}}}_{1\text{ 항}} \cdot \underbrace{\frac{\partial \hat{y}_{qn}}{\partial \beta_{qn}}}_{2\text{ 항}} \cdot \underbrace{\frac{\partial \beta_{qn}}{\partial w_{lq}}}_{3\text{ 항}}$$

$$\begin{aligned} \frac{\partial \epsilon_{MSE}(n)}{\partial \hat{y}_{qn}} &= \frac{\partial}{\partial \hat{y}_{qn}} \sum_{j=0}^{Q-1} (\hat{y}_{jn} - y_{jn})^2 \\ &= \frac{\partial}{\partial \hat{y}_{qn}} \left\{ (\hat{y}_{0n} - y_{0n})^2 + \cdots + (\hat{y}_{qn} - y_{qn})^2 + \cdots + (\hat{y}_{(Q-1)n} - y_{(Q-1)n})^2 \right\} \\ &= 2(\hat{y}_{qn} - y_{qn}) \end{aligned}$$

우변 2항

$$\frac{\partial \hat{y}_{qn}}{\partial \beta_{qn}} = \frac{\partial}{\partial \beta_{qn}} f(\beta_{qn}) = f(\beta_{qn}) (1 - f(\beta_{qn})) = \hat{y}_{qn} (1 - \hat{y}_{qn})$$

(참고) 시그모이드 함수의 미분

$$f'(x) = f(x)(1 - f(x))$$

# Error Back-Propagation 알고리즘



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.

- $\frac{\partial}{\partial w_{lq}} \epsilon_{MSE}(n)$  구하기

우변 3항


$$\frac{\partial}{\partial w_{lq}} \epsilon_{MSE}(n) = \frac{\partial \epsilon_{MSE}(n)}{\partial \hat{y}_{qn}} \cdot \frac{\partial \hat{y}_{qn}}{\partial \beta_{qn}} \cdot \frac{\partial \beta_{qn}}{\partial w_{lq}}$$

$$\frac{\partial \beta_{qn}}{\partial w_{lq}} = \frac{\partial}{\partial w_{lq}} \sum_{j=0}^L w_{jq} b_{jn} = \frac{\partial}{\partial w_{lq}} (w_{0q} b_{0n} + \dots + w_{lq} b_{ln} + \dots + w_{Lq} b_{Ln}) = b_{ln}$$

최종

$$\begin{aligned} \frac{\partial \epsilon_{MSE}(n)}{\partial w_{lq}} &= \frac{\partial \epsilon_{MSE}(n)}{\partial \hat{y}_{qn}} \cdot \frac{\partial \hat{y}_{qn}}{\partial \beta_{qn}} \cdot \frac{\partial \beta_{qn}}{\partial w_{lq}} \\ &= 2(\hat{y}_{qn} - y_{qn}) \hat{y}_{qn} (1 - \hat{y}_{qn}) b_{ln} \\ &= \delta_{qn} b_{ln} \end{aligned}$$

$\delta_{qn}$ :  $q$ 번째 output node에 대해,  
 $2 * \text{output} * (\text{output} - \text{target}) * (1 - \text{output})$





# Error Back-Propagation 알고리즘



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.


- $\frac{\partial}{\partial v_{ml}} \epsilon_{MSE}(n)$  구하기

$$\frac{\partial}{\partial v_{ml}} \epsilon_{MSE}(n) = \frac{\partial \epsilon_{MSE}(n)}{\partial b_{ln}} \cdot \frac{\partial b_{ln}}{\partial \alpha_{ln}} \cdot \frac{\partial \alpha_{ln}}{\partial v_{ml}}$$

우변 1항

$$\begin{aligned} \frac{\partial \epsilon_{MSE}(n)}{\partial b_{ln}} &= \frac{\partial}{\partial b_{ln}} \sum_{q=0}^{Q-1} (\hat{y}_{qn} - y_{qn})^2 = 2 \sum_{q=0}^{Q-1} (\hat{y}_{qn} - y_{qn}) \frac{\partial \hat{y}_{qn}}{\partial b_{ln}} \\ &= 2 \sum_{q=0}^{Q-1} (\hat{y}_{qn} - y_{qn}) \frac{\partial}{\partial b_{ln}} f \left( \sum_{j=0}^L w_{jq} b_{jn} \right) \\ &= 2 \sum_{q=0}^{Q-1} (\hat{y}_{qn} - y_{qn}) \frac{\partial}{\partial b_{ln}} f(w_{0q} b_{0n} + \dots + w_{lq} b_{ln} + \dots + w_{Lq} b_{Ln}) \\ &= 2 \sum_{q=0}^{Q-1} (\hat{y}_{qn} - y_{qn}) f \left( \sum_{j=0}^L w_{jq} b_{jn} \right) \left( 1 - f \left( \sum_{j=0}^L w_{jq} b_{jn} \right) \right) w_{lq} \\ &= 2 \sum_{q=0}^{Q-1} (\hat{y}_{qn} - y_{qn}) \hat{y}_{qn} (1 - \hat{y}_{qn}) w_{lq} \\ &= \sum_{q=0}^{Q-1} \delta_{qn} w_{lq} \end{aligned}$$

*l 번째 Hidden Node와 연결된 weight들과 Output Node를 고려하게 됨.*



# Error Back-Propagation 알고리즘



- $\frac{\partial}{\partial v_{ml}} \epsilon_{MSE}(n)$  구하기

우변 2항

$$\frac{\partial}{\partial v_{ml}} \epsilon_{MSE}(n) = \frac{\partial \epsilon_{MSE}(n)}{\partial b_{ln}} \cdot \frac{\partial b_{ln}}{\partial \alpha_{ln}} \cdot \frac{\partial \alpha_{ln}}{\partial v_{ml}}$$

$$\frac{\partial b_{ln}}{\partial \alpha_{ln}} = \frac{\partial}{\partial \alpha_{ln}} f(\alpha_{ln}) = f(\alpha_{ln})(1 - f(\alpha_{ln})) = b_{ln}(1 - b_{ln})$$

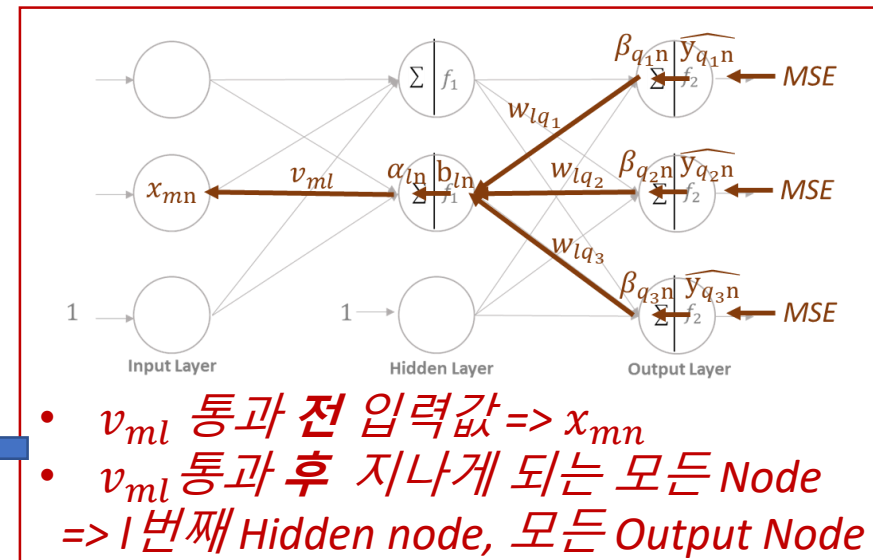
우변 3항

$$\frac{\partial \alpha_{ln}}{\partial v_{ml}} = \frac{\partial}{\partial v_{ml}} \sum_{j=0}^M v_{jl} x_{jn} = \frac{\partial}{\partial v_{ml}} (v_{0l} x_{0n} + \dots + v_{ml} x_{mn} + \dots + v_{Ml} x_{Mn}) = x_{mn}$$

최종

$$\frac{\partial \epsilon_{MSE}(n)}{\partial v_{ml}} = \frac{\partial \epsilon_{MSE}(n)}{\partial b_{ln}} \cdot \frac{\partial b_{ln}}{\partial \alpha_{ln}} \cdot \frac{\partial \alpha_{ln}}{\partial v_{ml}}$$

$$= \sum_{q=0}^{Q-1} \delta_{qn} w_{lq} b_{ln}(1 - b_{ln}) x_{mn}$$




## ■ 전체 알고리즘 적용 순서

- 1) 신경망 모델 설계 (Hidden Layer 수, Node 수, 활성화 함수, Learning Rate 등)
- 2) 설계된 모델에 따른 Weight Matrix 생성 및 초기화
- 3) N개의 훈련 데이터 Shuffle
- 4) 0부터 N-1번째 데이터에 대해 순차적으로 오차 역전파 알고리즘 적용 (1 epoch)
  - **for** n번째 데이터
    - (순전파) n-1에서 업데이트 된 Weight로부터 예측값  $\hat{y}_{qn}$  계산
    - (역전파) 실제값(Target)과 예측값(Output) 간의 오차로부터 Weight 업데이트 => 주의사항: Input layer에 가까운 weight부터 업데이트
- 5) 업데이트 된 weight로부터 accuracy 계산
- 6) 사용자가 입력한 epoch 수 만큼 3~4) 반복

# Two-Layer Neural Network 적용 예시



- 데이터
  - 2입력 3클래스 분류 데이터
    - 입력 속성: 출석률, 시험성적
    - 출력 속성: 학점 (A, B, C)



데이터 번호	입력		출력
	출석률	시험성적	학점
0	76	98	A
1	65	94	A
2	80	86	A
3	89	74	A
4	55	77	A
5	30	79	B
6	39	64	B
7	38	63	B
8	45	49	B
9	80	42	B
10	68	7	C
11	64	8	C
12	21	26	C
13	15	14	C
14	11	12	C



One-Hot Encoding



데이터 번호	입력		출력		
	출석률	시험성적	$y_0$	$y_1$	$y_2$
0	76	98	1	0	0
1	65	94	1	0	0
2	80	86	1	0	0
3	89	74	1	0	0
4	55	77	1	0	0
5	30	79	0	1	0
6	39	64	0	1	0
7	38	63	0	1	0
8	45	49	0	1	0
9	80	42	0	1	0
10	68	7	0	0	1
11	64	8	0	0	1
12	21	26	0	0	1
13	15	14	0	0	1
14	11	12	0	0	1

# Two-Layer Neural Network 적용 예시



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.

## ■ 학습 성공 시,



Confusion Matrix				
Output Class	dolphin	fish	noise	
	128 38.6%	0 0.0%	0 0.0%	100% 0.0%
	4 1.2%	111 33.4%	0 0.0%	96.5% 3.5%
	4 1.2%	2 0.6%	83 25.0%	93.3% 6.7%
				Target Class
				dolphin
				fish
				noise

Confusion Matrix					
True label	anger	happiness	fear	sadness	neutral
	0.81	0.054	0.12	0	0.014
	0.11	0.7	0.019	0	0.17
	0.025	0.062	0.8	0	0.11
	0	0	0.033	0.9	0.066
	0.02	0.07	0.05	0.01	0.85
Predicted label					

**Confusion Matrix로 나타내 보자**

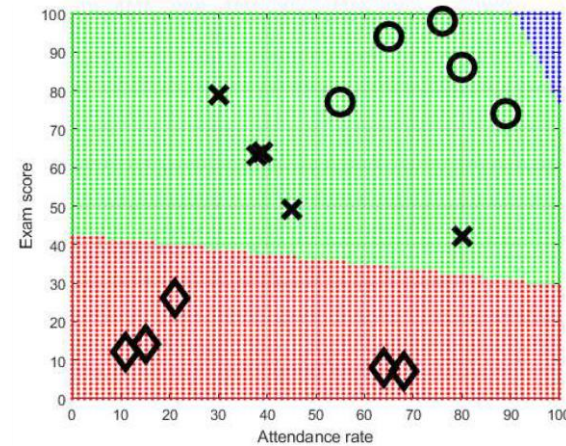
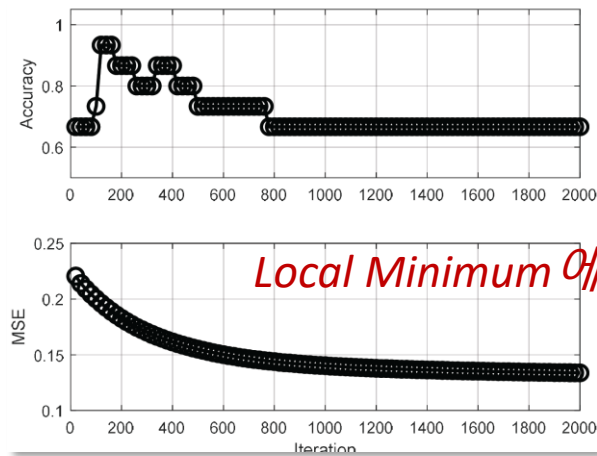
Confusion Matrix (모델 성능을 표현하는 가장 보편적 방법)

# Two-Layer Neural Network 적용 예시



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.

## ■ 학습 실패 시,




위의 결과를 Confusion Matrix로 나타내 보자

## ■ 다중 분류를 위한 Softmax Function

$$o_j = \frac{e^{s_j}}{\sum_{i=1,c} e^{s_i}}$$

### ■ 동작 예시

- softmax는 max를 모방(출력 노드의 중간 계산 결과  $s_i^L$ 에서 최댓값은 더욱 활성화하고 작은 값은 억제
- 모두 더하면 1이 되어 확률 모방



# Softmax Function



## ▪ Softmax를 출력함수로 사용할 때의 Cost Function

### • Cross-Entropy

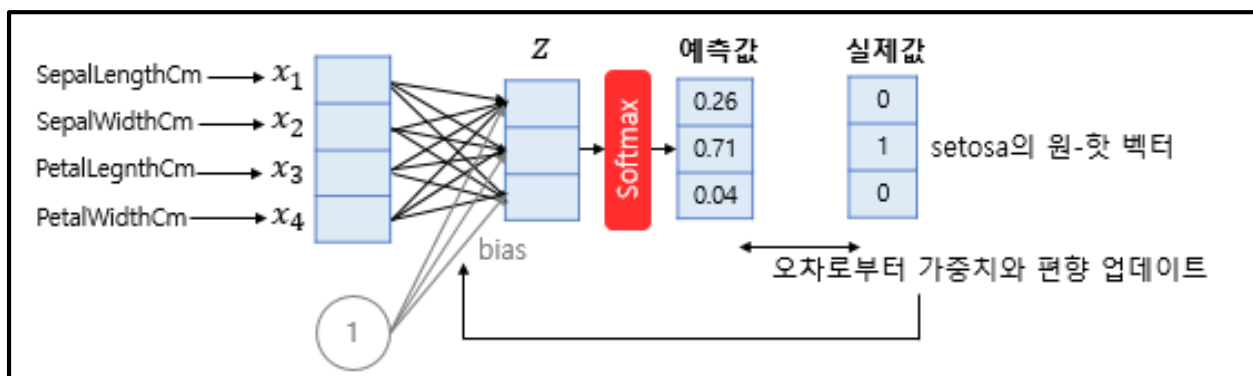

❖ 이진분류 => 
$$\epsilon_{CEE} = -\frac{1}{N} \sum_{n=0}^{N-1} \{y_n \ln p_n + (1 - y_n) \ln(1 - p_n)\}$$

$$\{y_n \ln p_n + (1 - y_n) \ln(1 - p_n)\}$$

$$= \{y_{0,n} \ln p_{0,n} + (y_{1,n}) \ln(p_{1,n})\}$$

$$= \sum_{k=0}^1 y_{k,n} \ln p_{k,n} \Rightarrow \sum_{k=0}^{K-1} y_{k,n} \ln(p_{k,n})$$


$$\epsilon_{CEE} = -\frac{1}{N} \sum_{n=0}^{N-1} \sum_{k=0}^{K-1} y_{i,n} \ln(p_{i,n})$$







<https://www.youtube.com/watch?v=aircAruvnKk>

## Neural Networks



From the  
ground up

# [참고] Deep Learning으로의 확장




*Node의 활성화 함수가 모두 동일하다고 했을 때,  
w1을 update하기 위해서는 활성화 함수의 도함수를 3번 곱한 값이 들어감.*

# Deep Learning으로의 확장




지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.

Sigmoid 함수



Sigmoid의 도함수




**“Gradient Vanishing Problem”**



도함수를 곱할수록 값이 작아져  
Weight Update가 잘 이뤄지지 않음.  
**=> Hidden Layer가 많을수록 불리**


ReLU 함수

Gradient Vanishing 문제를  
해결하기 위해 제안된 활성화 함수  
ReLU



$$f(x) = \begin{cases} 0 & x < 0 \\ x & x \geq 0 \end{cases} \quad f(x) = \max(0, x)$$


dReLU(x)/dx




**Hidden Layer가 많아도,  
즉, Neural Network가 Deep해져도  
Weight를 업데이트 할 수 있음**

## ■ Dropout (드롭아웃)

- 신경망의 일부 Node를 랜덤으로 비활성화하며 훈련시키는 기법
- Regularization (Overfitting을 방지하기 위해 사용)



(a) Standard Neural Net




(b) After applying dropout.

각 node가 존재할 확률  $p$

통상 알려진 default    입력층: 0.8  
                                 은닉층: 0.5

출력층은?

## Dropout에서의 Training 단계



$l$ 번째 은닉층의  $j$ 번째 노드의 연산:

$$z_j^l = \tau_l(s_j^l)$$

이때  $s_j^l = \mathbf{u}_j^l \mathbf{z}^{l-1}$

$\Rightarrow$

드롭아웃 적용:

$$z_j^l = \tau_l(s_j^l)$$



이때 
$$\begin{cases} \tilde{\mathbf{z}}^{l-1} = \mathbf{z}^{l-1} \odot \boldsymbol{\pi}^{l-1} \\ s_j^l = \mathbf{u}_j^l \tilde{\mathbf{z}}^{l-1} \end{cases}$$

Boolean 배열  $\boldsymbol{\pi}$ 에 노드 제거 여부를 표시

*Boolean 배열: 배열 내부에 True or False 만 존재*

## ■ Dropout에서의 Test 단계

- 가중치에 생존 비율( $p$ )을 곱하여 전방 계산
- 학습 과정에서 가중치가 생존 비율( $p$ ) 만큼만 참여했기 때문



# Chap.4 실습 - 2주차



*각 실습문제에 대해 code(+ 주석), 그래프, 분석 내용 등은 필수적으로 포함시킬 것*

- 1) Error Back-Propagation 알고리즘 구현
  - Chap. 4 강의자료 24 page에 나와있는 알고리즘을 사용자 지정함수로 구현
- 2) Two-Layer Neural Network “Training”
  - “NN\_data.csv”를 7:3 으로 Training set :Test set 분할
  - Training set과 1)에서 구현한 알고리즘으로부터 Two-Layer Neural Network를 Training
  - Epoch에 따른 Accuracy 및 MSE 그래프 도출
  - Hyper-parameter tuning을 통해 최적화
- 3) Two-Layer Neural Network “Test”
  - 2)에서 도출한 Two-Layer Neural Network에 Testing set 삽입
  - Confusion Matrix 도출